Trabalho Pratico 01 - Classificacao KNN sobre a base Iris

GCC 128 - Inteligencia Artificial - UFLA | Profs. Ahmed Ali Abdalla Esmin / Anna Paula Figueiredo
Autor(es): Joao Vitor Givisiez Lessa

1. Metodologia

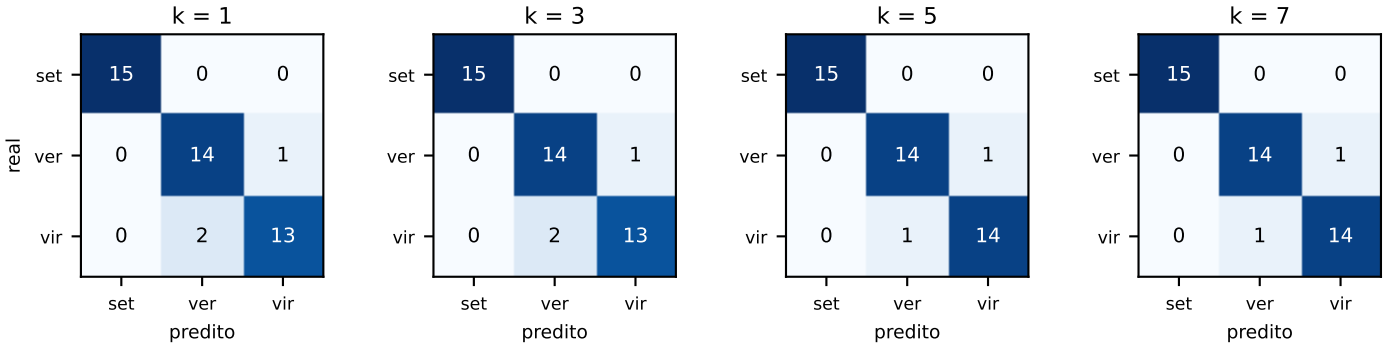
Base Iris (150 amostras, 4 atributos, 3 classes balanceadas), dividida em 70% treino (105) e 30% teste (45) por particao estratificada com semente fixa. As duas implementacoes recebem exatamente a mesma particao e a mesma metrica (distancia euclidiana), de modo que qualquer diferenca de resultado viria do algoritmo. A versao hardcore implementa do zero o calculo de distancias, a selecao dos k vizinhos (np.argpartition, O(n)), a votacao majoritaria e tambem as metricas de avaliacao, sem usar sklearn.metrics.

2. Comparacao das metricas de avaliacao

k	Acur. HC	Acur. SK	Prec. HC	Prec. SK	Revoc. HC	Revoc. SK	F1 HC	F1 SK
1	0.9333	0.9333	0.9345	0.9345	0.9333	0.9333	0.9333	0.9333
3	0.9333	0.9333	0.9345	0.9345	0.9333	0.9333	0.9333	0.9333
5	0.9556	0.9556	0.9556	0.9556	0.9556	0.9556	0.9556	0.9556
7	0.9556	0.9556	0.9556	0.9556	0.9556	0.9556	0.9556	0.9556

HC = implementacao hardcore | SK = Scikit-learn. Precisao, revocacao e F1 sao medias macro sobre as 3 classes.

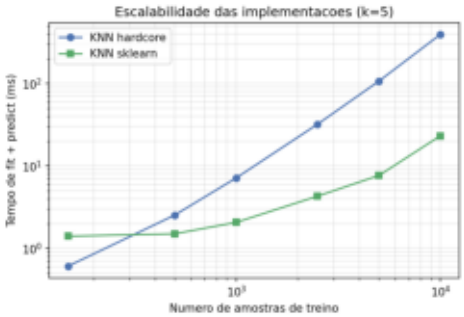
3. Matrizes de confusao (identicas nas duas implementacoes)



4. Desempenho computacional

k	Tempo HC (ms)	Tempo SK (ms)	Razao HC/SK	Mem. HC (KB)	Mem. SK (KB)
1	0.648	1.065	0.61x	8.8	26.2
3	0.685	1.109	0.62x	8.7	29.8
5	0.693	1.109	0.62x	8.7	33.4
7	0.726	1.097	0.66x	8.7	36.7

Tempo: melhor de 10 execucoes de fit + predict. Memoria: pico via tracemalloc.



5. Analise dos resultados

Equivalencia. As duas implementacoes produziram resultados identicos para todos os k testados: nao apenas as metricas coincidem, mas a predicao de cada uma das 45 amostras de teste (concordancia de 100%). Isso e o esperado, ja que o KNN e deterministico -- fixadas a particao, a distancia e a regra de desempate, nao ha espaco para divergencia. Na pratica, essa coincidencia funciona como validacao da implementacao propria.

Efeito de k. A taxa de reconhecimento passou de 93,33% (k=1 e k=3) para 95,56% (k=5 e k=7). Com k maior a fronteira de decisao fica mais suave e menos sensivel a ruido; com k=1 a decisao depende de um unico vizinho, o que torna o modelo instavel proximo a fronteira entre classes.

Erros. Todos os erros ocorreram entre versicolor e virginica, as duas classes que se sobrepoem no espaco de atributos. A classe setosa, linearmente separavel, teve precisao e revocacao de 1,00 em todas as configuracoes. O aumento de k corrigiu exatamente um erro de virginica classificada como versicolor.

Custo computacional. Na base Iris a implementacao hardcore foi cerca de 1,6x mais rapida e usou 3 a 4x menos memoria que a do Scikit-learn. O resultado e contraintuitivo, mas tem explicacao: com apenas 105 amostras de treino, o tempo do sklearn e dominado por overhead fixo (validacao de entrada e construcao da KD-tree) que nao chega a ser amortizado. Esse ganho nao generaliza. O teste de escalabilidade (grafico acima) mostra a inversao: a partir de ~500 amostras o sklearn ja e mais rapido e, com 10.000 amostras, chega a ser mais de 20x superior -- a versao hardcore e O(n) por consulta em Python puro, enquanto o sklearn usa indexacao e codigo compilado.

6. Conclusao

Do ponto de vista da qualidade da classificacao os dois classificadores sao equivalentes, o que confirma a corretude da implementacao feita do zero. A diferenca relevante esta no custo computacional e na robustez: a versao propria vence apenas no regime de base muito pequena, enquanto a biblioteca escala muito melhor e ainda oferece tratamento de casos de borda, outras metricas de distancia e paralelizacao. Para fins didaticos, implementar o algoritmo do zero e o que torna explicito o seu funcionamento; para uso real, a biblioteca e a escolha adequada.